

# Makine Öğrenmesi

## Sınıflandırma ve Ağaçlar

**İlker Birbil ve Utku Karaca**

Erasmus Üniversitesi Rotterdam

İstanbul'da Makine Öğrenmesi

27 Ocak – 2 Şubat, 2020



# Makine Öğrenmesi

```
graph TD; A[Makine Öğrenmesi] --> B[Doğrusal Bağlanım]; A --> C[Boyut Küçültme ve Düzenleştirme]; A --> D[Tekrar Örnekleme ve Model Değerlendirme]; A --> E[Sınıflandırma ve Ağaçlar]; A --> F[Güdümsüz Öğrenme]; A --> G[Yapay Sinir Ağları ve Derin Öğrenme];
```

Doğrusal Bağlanım


Boyut Küçültme  
ve  
Düzenleştirme

Tekrar Örnekleme  
ve  
Model Değerlendirme

Sınıflandırma  
ve  
Ağaçlar

Güdümsüz  
Öğrenme

Yapay Sinir Ağları  
ve  
Derin Öğrenme



eğitim verisi  
 $\{(x_i, y_i) : 1, \dots, n\}$

# Lojistik Bağlanım (Logistic Regression)

$X_1$  : toplam harcama (bakiye)

$X_2$  : yıllık gelir

$X_3$  : öğrenci (1), öğrenci değil (0)



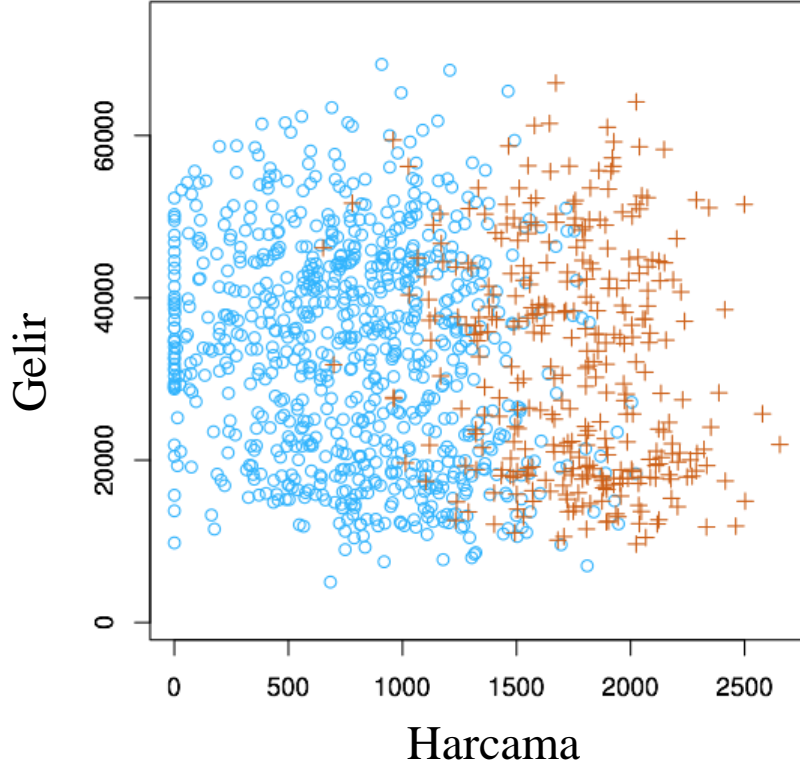
$$Y = \begin{cases} \text{kart borcu kalan (borçlu),} & 1; \\ \text{kart borcu kalmayan (borçsuz),} & 0. \end{cases}$$

$$p(X) = \mathbb{P}(Y = 1|X) \quad ?$$

$$p(X) = \mathbb{P}(Y = 1|X) > \tau$$



eşik değer (threshold)



$$p(X) = \mathbb{P}(Y = 1|X) \quad ?$$

$$p = 1$$

$$p(X) = \beta_0 + \beta_1 X \longrightarrow (-\infty, +\infty)$$

$$p(X) = \sigma(\beta_0 + \beta_1 X) \longrightarrow [0, 1]$$

?

Sigmoid Fonksiyonu


$$\sigma(y) = \frac{e^y}{1 + e^y}$$

Lojistik Fonksiyonu


$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} \longrightarrow [0, 1]$$

$$p(X) = \mathbb{P}(Y = 1|X) \quad ?$$

$$p(X) = \beta_0 + \beta_1 X \longrightarrow (-\infty, +\infty) \quad p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} \longrightarrow [0, 1]$$



Harcama



Harcama

$$\log \left( \underbrace{\frac{p(X)}{1 - p(X)}} \right) = \beta_0 + \beta_1 X$$

göreceli olasılıklar (odds)

$$p > 1$$

$$p(X) = \sigma(\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p)$$

Lojistik Fonksiyonu

$$p(X) = \frac{e^{\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p}}$$


$$\beta_0, \beta_1, \dots, \beta_p?$$



eğitim verisi

$$\{(x_i, y_i) : 1, \dots, n\}$$





Olabilirlik (Likelihood) Fonksiyonu

$$\ell(\beta_0, \dots, \beta_p) = \prod_{i: y_i=1} p(x_i) \prod_{j: y_j=0} (1 - p(x_j))$$

# En Büyük (Maximum) Olabilirlik

$$\ell(\beta_0, \dots, \beta_p) = \prod_{i:y_i=1} p(x_i) \prod_{j:y_j=0} (1 - p(x_j))$$

$$\max_{\beta_0, \dots, \beta_p} \ell(\beta_0, \dots, \beta_p)$$



$$\max_{\beta_0, \dots, \beta_p} \log(\ell(\beta_0, \dots, \beta_p))$$



$$\max_{\beta_0, \dots, \beta_p} \sum_{i:y_i=1} \log p(x_i) + \sum_{j:y_j=0} \log(1 - p(x_j))$$



İçbükey Fonksiyon



$$\hat{\beta}_0, \dots, \hat{\beta}_p$$

$$p = 1$$

	Katsayı	St. Hata	Z istatistiği	<i>p</i> değeri
<b>Kesme nok.</b>	-3,5041	0,0707	-49,55	< 0,0001
<b>Öğrenci (1)</b>	0,4049	0,1150	3,52	0,0004

$$p > 1$$

	Katsayı	St. Hata	Z istatistiği	<i>p</i> değeri
<b>Kesme nok.</b>	-10,8690	0,4923	-22,08	< 0,0001
<b>Harcama</b>	0,0057	0,0002	24,74	< 0,0001
<b>Gelir</b>	0,0030	0,0082	0,37	0,7115
<b>Öğrenci (1)</b>	-0,6468	0,2362	-2,74	0,0062

Parazit Etkisi (Confounding Effect)

## Tahmin Yapma

	Katsayı	St. Hata	Z istatistiği	<i>p</i> değeri
<b>Kesme nok.</b>	-10,8690	0,4923	-22,08	< 0,0001
<b>Harcama</b>	0,0057	0,0002	24,74	< 0,0001
<b>Gelir</b>	0,0030	0,0082	0,37	0,7115
<b>Öğrenci (1)</b>	-0,6468	0,2362	-2,74	0,0062

$$X = \begin{bmatrix} 1.500 \\ 40.000 \\ 1 \end{bmatrix}$$

$$p(X) = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}$$

$$\hat{p}(X) = \frac{e^{-10,869 + 0,0057 \times 1.500 + 0,003 \times 40 - 0,6468 \times 1}}{1 + e^{-10,869 + 0,0057 \times 1.500 + 0,003 \times 40 - 0,6468 \times 1}} = 0.058$$

# Doğrusal Ayrımlayıcı Çözümleme (Linear Discriminant Analysis - LDA)

$$\mathbb{P}(Y = k|X = x) \quad \longleftrightarrow \quad \mathbb{P}(X = x|Y = k)$$



Bayes Kuramı

$$\mathbb{P}(Y = k|X = x) = \frac{\overbrace{\mathbb{P}(Y = k)}^{\pi_k} \overbrace{\mathbb{P}(X = x|Y = k)}^{f_k(x)}}{\sum_{l=1}^K \mathbb{P}(Y = l) \mathbb{P}(X = x|Y = l)}$$

Ardıl Olasılık (Posterior Probability)

$$p_k(x) = \frac{\pi_k f_k(x)}{\sum_{l=1}^K \pi_l f_l(x)}$$

$\pi_k$  ?

$f_k(x)$  ?

$$f_k(x) \text{ ?}$$


$$p = 1$$

$$p_k(x) = \frac{\pi_k f_k(x)}{\sum_{l=1}^K \pi_l f_l(x)}$$

**Kabul 1:**  $X \sim N(\mu, \sigma)$

$$f_k(x) = \frac{1}{\sqrt{2\pi\sigma_k}} \exp\left(-\frac{1}{2\sigma_k^2}(x - \mu_k)^2\right)$$

**Kabul 2:**  $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_K^2 = \sigma^2$



$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu_k)^2\right)}{\sum_{l=1}^K \pi_l \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu_l)^2\right)}$$

$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2} (x - \mu_k)^2\right)}{\sum_{l=1}^K \pi_l \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2} (x - \mu_l)^2\right)}$$

$$\log(p_k(x)) = \log\left(\frac{\pi_k \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2} (x - \mu_k)^2\right)}{\sum_{l=1}^K \pi_l \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2} (x - \mu_l)^2\right)}\right)$$

⋮

$$= \underbrace{x \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k)}_{\delta_k(x)} - C$$

$k$ 'den bağımsız  
sabit terim

$$\delta_k(x) = x \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k)$$

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i:y_i=k} x_i \quad \hat{\sigma}^2 = \frac{1}{n-K} \sum_{k=1}^K \sum_{i:y_i=k} (x_i - \hat{\mu}_k)^2 \quad \hat{\pi}_k = \frac{n_k}{n}$$

$$\hat{\delta}_k(x) = x \frac{\hat{\mu}_k}{\hat{\sigma}^2} - \frac{\hat{\mu}_k^2}{2\hat{\sigma}^2} + \log(\hat{\pi}_k)$$

$$X = x$$

$$\hat{\delta}_k(x) \quad \uparrow \uparrow$$


$$Y = k$$



$$\boxed{p > 1} \quad X = (X_1, X_2, \dots, X_p)$$

**Kabul 1:**  $X \sim N(\mu, \Sigma)$

$$f_k(x) = \frac{1}{(2\pi)^{p/2} |\Sigma_k|^{1/2}} \exp \left( -\frac{1}{2} (x - \mu_k)^\top \Sigma_k^{-1} (x - \mu_k) \right)$$



**Kabul 2:**  $\Sigma_1 = \Sigma_2 = \dots = \Sigma_K = \Sigma$

$$\delta_k(x) = x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log(\pi_k)$$

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i:y_i=k} x_i \qquad \hat{\pi}_k = \frac{n_k}{n}$$

$$\hat{\Sigma} = \frac{1}{n-K} \sum_{k=1}^K \sum_{i:y_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^\top$$

$$\hat{\delta}_k(x) = x^\top \hat{\Sigma}^{-1} \hat{\mu}_k - \frac{1}{2} \hat{\mu}_k^\top \hat{\Sigma}^{-1} \hat{\mu}_k + \log(\hat{\pi}_k)$$

$$X = x$$

$$\hat{\delta}_k(x) \quad \uparrow \uparrow$$

$$Y = k$$


$$p(X) = \mathbb{P}(Y = 1|X) > \tau$$

$\tau = 0.5$		Gerçek		
		Borçsuz	Borçlu	Toplam
Tahmin	Borçsuz	9.644	252	9.896
	Borçlu	23	81	104
	Toplam	9.667	333	10.000

$\tau = 0.2$		Gerçek		
		Borçsuz	Borçlu	Toplam
Tahmin	Borçsuz	9.432	138	9.570
	Borçlu	235	195	430
	Toplam	9.667	333	10.000

# ROC\* Grafiđi

(Karar Deđerlendirme Grafiđi)



\* Receiver Operating Characteristics

## Hata Matrisi (Confusion Matrix)

		Tahmin Edilen Sınıf		
		-	+	Toplam
Gerçek Sınıf	-	Gerçek Negatif (GN)	Yanlış Pozitif (YP)	N
	+	Yanlış Negatif (YN)	Gerçek Pozitif (GP)	P
	Toplam	N*	P*	

		Tahmin Edilen Sınıf		
		-	+	Toplam
Gerçek Sınıf	-	GN	YP	N
	+	YN	GP	P
	Toplam	N*	P*	

İsim	Hesap	Eş Anlam
<b>Yanlış Bulma Oranı<sup>a</sup></b>	YP/N	birinci tip hata (type I error), 1 – özgüllük (specifity)
<b>Doğru Bulma Oranı<sup>b</sup></b>	GP/P	1 – ikinci tip hata (type II error), üs, duyarlılık (sensitivity), doğruluk (recall)
<b>Pozitif Tahmin Değeri<sup>c</sup></b>	GP/P*	kesinlik (precision), 1 – yanlış keşif oranı (false discovery proportion)
<b>Negatif Tahmin Değeri<sup>d</sup></b>	GN/N*	

<sup>a</sup> False Positive Rate

<sup>b</sup> True Positive Rate


<sup>c</sup> Positive Predictive Value

<sup>d</sup> Negative Predictive Value

# Karar Ağaçları (Decision Trees)


**Amaç:** Değişkenler uzayını basit alt bölgelere ayırmak

Bağlanım Ağaçları  
Sınıflandırma Ağaçları




Topluluk Yöntemleri

Torbalama (Bagging) ve  
Rasgele Ormanlar (Random Forests)





Takviye (Boosting)



# Örnek Ağaç

Bir beyzbol oyuncusunun maaşının yaptığı vuruş ve oynadığı toplam yıla göre tahmin edilmesi





# Bağlanım Ağaçları

$$X_1, X_2, \dots, X_p \xrightarrow{\text{Çakışmayan bölgeler}} R_1, R_2, \dots, R_J$$

**Tahmin:**  $R_j$  bölgesindeki eğitim verisinin çıktı değerlerinin ( $y_i$ ) ortalaması

$$R_1, R_2, \dots, R_J \quad ?$$

**Amaç:** KKT değerinin en küçük olduğu bölgelerin bulunması

$$\sum_{j=1}^J \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2$$

$\hat{y}_{R_j}$  :  $R_j$  bölgesindeki çıktıların ortalaması

# Bağlanım Ağaçları





## Özyinelemeli İkili Ayırma (Recursive Binary Splitting)

$$R_1(j, s) = \{X | X_j < s\} \quad R_2(j, s) = \{X | X_j \geq s\}$$

Aşağıdaki ifadeyi en küçükleyen  $j$  ve  $s$  değerlerini bul

$$\sum_{i: x_i \in R_1(j, s)} (y_i - \hat{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j, s)} (y_i - \hat{y}_{R_2})^2$$

Terminal düğümde çok az veri noktası kalınca **dur!**



# Bağlanım Ağaçları

## Ağaç Budama (Tree Pruning)

**Amaç:** Ağacın tamamı ya da büyük kısmı oluşunca ortaya çıkan aşırı öğrenmenin önüne geçmek (düşük *test* hatası)

$$\sum_{m=1}^{|T|} \sum_{i: x_i \in R_m} (y_i - \hat{y}_{R_m})^2 + \alpha |T|$$

$T \subset T_0$  : alt ağaç (subtree)

$|T|$  :  $T$  ağacındaki terminal düğüm sayısı

$R_m$  :  $m$ . terminal düğüme karşılık gelen bölge

$\alpha$  : sabit parametre

$\alpha \uparrow$        $|T| \downarrow$

$\alpha$  parametresini bulmak için  $k$ -katlı çapraz geçerlilik sınaması yapılır


# Sınıflandırma Ağaçları

Bağlanım ağaçlarına çok benzer şekilde ilerlenir ancak alt bölgenin *saflık* derecesine bağlı bir hata ölçüsü kullanılır

$\hat{p}_{mk}$  :  $m$ . bölgedeki eğitim verisindeki  $k$ . sınıftan olanların oranı


## Sınıflandırma Hata Oranı

$$E = 1 - \max_k \{\hat{p}_{mk}\}$$



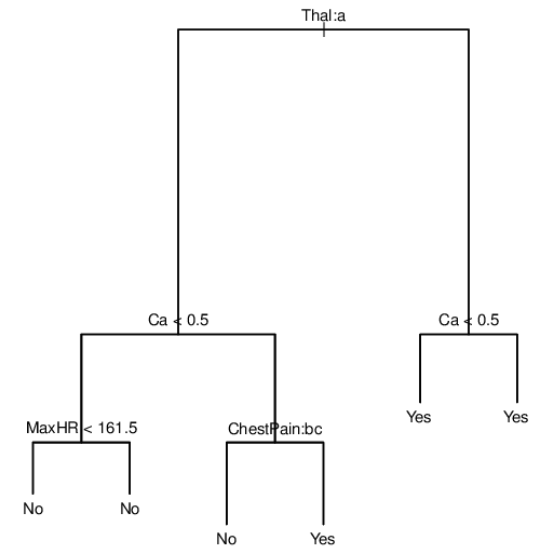
## Entropi

$$D = - \sum_{k=1}^K \hat{p}_{mk} \log \hat{p}_{mk}$$



## Gini İndeksi


$$G = \sum_{k=1}^K \hat{p}_{mk}(1 - \hat{p}_{mk})$$



# Topluluk Yöntemleri

## Torbalama

**Amaç:** Varyansı düşürmek için zorlama tekniğini kullanarak birkaç tane büyük ağaç oluşturulur ve onların tahminlerinin ortalaması (bağlanım) ya da çoğunlukta olan sınıf (sınıflandırma) hesaplanır.



## Bağlanım

$B$  : farklı eğitim kümesi sayısı

$\hat{f}^{*b}(x)$  :  $b$ . eğitim kümesi ile elde edilen tahmin

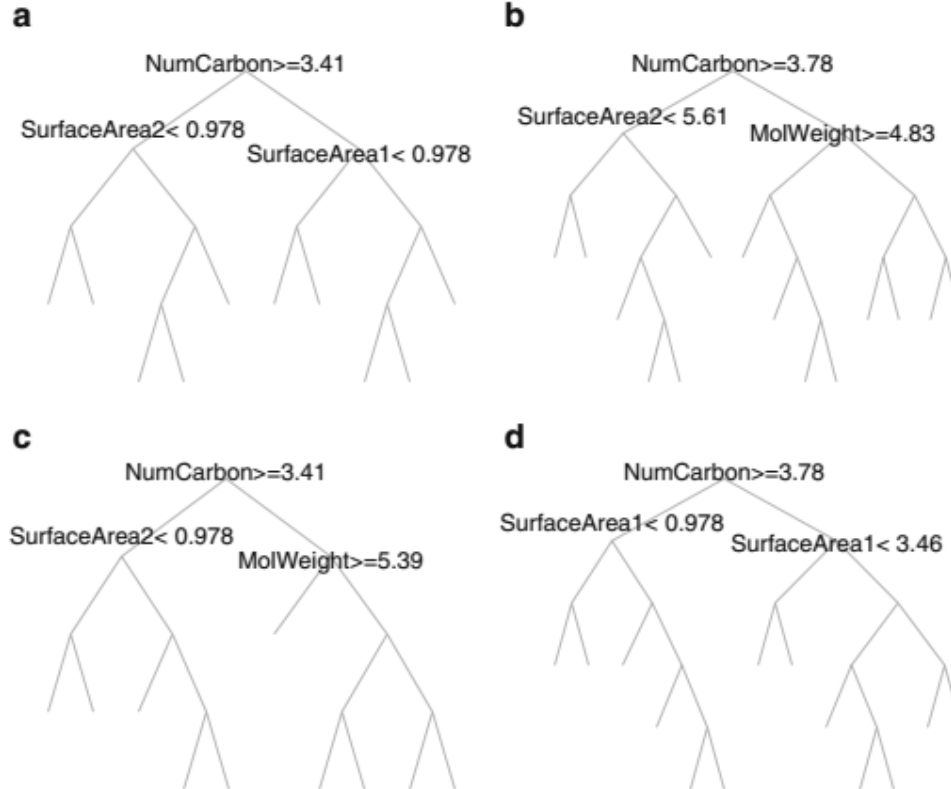
$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x)$$

# Topluluk Yöntemleri

## Rasgele Ormanlar

**Amaç:** Ağaçlar arasındaki korelasyonu azaltmak için dalları ayırırken tüm değişkenler yerine sadece rassal sayıda değişkeni kullanmak

Neden?




\*



# Topluluk Yöntemleri

## Takviye

**Fikir:** Fazla etkin olmayan sınıflandırıcıları, ağırlıklı veri örnekleme tekniğini kullanarak bir araya getirerek daha etkin bir sınıflandırıcı elde etmek



**Güncelleme Kuralı:** Yanlış sınıflandırılan veri noktalarının ağırlıklarını artır

# Ensemble Methods

## AdaBoost – İkili Sınıflandırma $\{+1, -1\}$

Her bir veri satırı başlangıçta aynı ağırlığa sahip:  $(1/n)$

**for**  $k=1$  to  $K$  **do**

ağırlıklı verileri kullanarak  $d$  dallı bir ağaç eğit ve and yanlış sınıflandırma hatasını hesapla ( $\epsilon_k$ )

Ağırlık değerini hesapla  $\ln \frac{1 - \epsilon_k}{\epsilon_k}$

Ağırlıklı verileri güncelle – yanlış sınıflandırılan verilere daha fazla ağırlık ver

**end**

Her bir veri için  $k$ . aşamadaki değer ile  $k$ . model tahminini çarparak takviyeli sınıflandırıcının tahminlerini hesapla ve bu miktarları  $k$ 'ye ekle. Eğer toplam pozitif ise veriyi +1 olarak sınıflandır, değilse -1.

Kitaptaki Algoritma 8.2 **bağlanım ağaçları** için takviye örneği veriyor.

# Topluluk Yöntemleri

## AdaBoost – İkili Sınıflandırma $\{+1, -1\}$

---

### Algoritma 1: AdaBoost

---

- 1 Başlangıç ağırlıklarını belirle:  $w_i^1 = \frac{1}{n}$ ,  $i = 1, \dots, n$
- 2 **for**  $k = 1, \dots, K$  **do**
- 3      $y_k(x)$  sınıflandırıcısını şu ağırlıklı sınıflandırma hata fonksiyonu ile eğit:

$$\sum_{i=1}^n w_i^k I(y_k(x_i) \neq y_i)$$

Yanlış sınıflandırılan veri noktalarının oransal ağırlığını hesapla:


$$\varepsilon^k = \frac{\sum_{i=1}^n w_i^k I(y_k(x_i) \neq y_i)}{\sum_{i=1}^n w_i^k}$$

- 4     Güncelleme parametresini belirle:  $\alpha_k = \ln \frac{1-\varepsilon_k}{\varepsilon_k}$
  - 5     Ağırlıkları güncelle:  $w_i^{k+1} = w_i^k e^{\alpha_k I(y_k(x_i) \neq y_i)}$ ,  $i = 1, \dots, n$
  - 6 **Çıktı:**  $\sum_{k=1}^K \alpha_k y_k(x)$  değerinin işareti (+1 ya da -1)
- 

(AdaBoost Özeti)

# Topluluk Yöntemleri

- Takviye ve torbalama yöntemleri başka yöntemler ile de uygulanabilirler
- Torbalama yöntemi paralel uygulama için son derece uygun olmasına rağmen takviye yöntemi sıralı yapısı nedeniyle paralelleştirmeye uygun değildir
- Topluluk yöntemleri ile elde edilen modeli yorumlamak güçtür
- Değişken önemini (variable importance) gösteren grafikler kullanılabilir



Bir **değişkenin önemi** Gini indeksinde ya da entropide elde ettiği ortalama azaltmaya göre belirlenir. Daha sonra değişkenler bu önem sırasına göre oranlanarak sıralanır.

# Pratikte

```
# Required packages
from sklearn.tree import DecisionTreeClassifier
from sklearn.datasets import make_classification
from sklearn.ensemble import BaggingClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.ensemble import AdaBoostClassifier

# Generate and extract features and target data
X, y = make_classification(n_samples=1000,
                          n_features=4,
                          n_informative=2,
                          n_redundant=0,
                          random_state=0,
                          shuffle=False)

# Create decision tree and train it
DTClassifier = DecisionTreeClassifier(criterion = 'gini',
                                     splitter = 'best',
                                     max_depth = None,
                                     min_samples_leaf = 5)

DTClassifier.fit(X, y)
DTClassifier.score(X, y)

# Bagging
bagging = BaggingClassifier(DTClassifier,
                            n_estimators = 20,
                            max_samples = 1.0,
                            bootstrap = True,
                            bootstrap_features = False)

bagging.fit(X, y)
bagging.score(X, y)

# Random Forest
RF = RandomForestClassifier(criterion = 'gini',
                           n_estimators=10,
                           max_depth=None,
                           min_samples_leaf = 5,
                           random_state=0)

RF.fit(X,y)
RF.score(X,y)

# Adaboost
ABC = AdaBoostClassifier(n_estimators=100, random_state=0)
ABC.fit(X, y)
ABC.score(X,y)
```

paketler ve fonksiyonlar

verinin yaratılması

karar ağacı uydurumu ve  
performansının raporlanması

topluluk yöntemleri

torbalama yöntemi kullanımı  
ve performansının  
raporlanması

```
...: [DTClassifier.score(X, y),
...:  bagging.score(X, y),
...:  RF.score(X,y),
...:  ABC.score(X,y)]
out[2]: [0.97, 0.973, 0.975, 0.983]
```

rastgele ormanlar yöntemi  
kullanımı ve performansının  
raporlanması

AdaBoost yönteminin kullanımı ve  
performansının raporlanması

# Destek Vektör Makineleri - DVM (Support Vector Machines - SVM)

$$(x_i, y_i), \quad i = 1, 2, \dots, n$$



$$x_i \in \mathbb{R}^p \qquad y_i \in \{-1, +1\}$$

**Fikir:** Bir düzlem (hyperplane) yardımıyla veri noktalarını iki sınıfa ayırmak


## Düzlem

$$\{X \in \mathbb{R}^p : \beta^\top X + \beta_0 = 0, \beta \in \mathbb{R}^p, \beta_0 \in \mathbb{R}\}$$

# Tam Ayrıştırılabilir Veri



# Tam Ayrıştırılabilir Veri






# Tam Ayrıştırılabilir Veri

**Amaç:**  $\beta$  ve  $\Delta$  parametrelerini,

$$\beta^\top X + \beta_0 - \Delta = 0 \quad \text{ve} \quad \beta^\top X + \beta_0 + \Delta = 0$$

ile gösterilen iki düzlem arasındaki mesafe en fazla olacak şekilde seçmek

Eşitliklerin her iki tarafı  $\Delta$  değerine bölünüp,  $\Delta = 1$  olarak alınabilir

$$\begin{array}{lcl} (x_i, y_i) & \begin{array}{l} \nearrow \\ \searrow \end{array} & \begin{array}{l} y_i = 1 \\ y_i = -1 \end{array} \quad \begin{array}{l} \longrightarrow \\ \longrightarrow \end{array} \quad \begin{array}{l} \beta^\top x_i + \beta_0 - 1 \geq 0 \\ \beta^\top x_i + \beta_0 + 1 \leq 0 \end{array} \end{array}$$



$$y_i(\beta^\top x_i + \beta_0) \geq 1$$

# Tam Ayrıştırılabilir Veri

**Amaç:**  $\beta$  ve  $\Delta$  parametrelerini,

$$\beta^\top X + \beta_0 - \Delta = 0 \quad \text{ve} \quad \beta^\top X + \beta_0 + \Delta = 0$$

ile gösterilen iki düzlem arasındaki mesafe en fazla olacak şekilde seçmek



$\beta$ : alt uzaya dik doğrultu

$$\beta^\top x = 0$$

Ayrıca  $\beta$  vektörü

$$\beta^\top x + \beta_0 = 1$$

ve

$$\beta^\top x + \beta_0 = -1$$



düzlemlerine de dik

# Tam Ayrıştırılabilir Veri

Amaç:  $\beta$  ve  $\Delta$  parametrelerini,

$$\beta^\top X + \beta_0 - \Delta = 0 \quad \text{ve} \quad \beta^\top X + \beta_0 + \Delta = 0$$

ile gösterilen iki düzlem arasındaki mesafe en fazla olacak şekilde seçmek



İki düzlem arasındaki mesafe:  $\frac{1 - \beta_0}{\|\beta\|} - \frac{-1 - \beta_0}{\|\beta\|} = \frac{2}{\|\beta\|}$

# Tam Ayrıştırılabilir Veri

Amaç:  $\beta$  ve  $\Delta$  parametrelerini,

$$\beta^\top X + \beta_0 - \Delta = 0 \quad \text{ve} \quad \beta^\top X + \beta_0 + \Delta = 0$$

ile gösterilen iki düzlem arasındaki mesafe en fazla olacak şekilde seçmek



$$\begin{aligned} &\text{enbüyük} && \frac{2}{\|\beta\|} \\ &\text{öyle ki} && y_i(\beta^\top x_i + \beta_0) \geq 1, \quad i = 1, \dots, n \end{aligned}$$

$$\begin{aligned} &\equiv && \frac{1}{2} \|\beta\| \\ &\text{enküçük} && \\ &\text{öyle ki} && y_i(\beta^\top x_i + \beta_0) \geq 1, \quad i = 1, \dots, n \end{aligned}$$


$$\begin{aligned} &\equiv && \frac{1}{2} \beta^\top \beta \\ &\text{enküçük} && \\ &\text{öyle ki} && y_i(\beta^\top x_i + \beta_0) \geq 1, \quad i = 1, \dots, n \end{aligned}$$

Bu matematiksel model, karesel ve **dışbükey** amaç fonksiyonu ile **doğrusal** kısıtlardan oluşuyor. Bu yapıdaki modellere **karesel programlama** (quadratic programming) modelleri denir.

# Tam Ayrıştırılabilir Veri




# Tam Ayrıştırılamayan Veri



- (A)  $y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon, \quad \varepsilon = 0$
- (B)  $y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon, \quad 0 < \varepsilon < 1$
- (C)  $y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon, \quad \varepsilon \geq 1$

# Tam Ayrıştırılamayan Veri




(A)  $y_i(\beta^\top x_i + \beta_0) \geq 1 - \varepsilon, \quad \varepsilon = 0$

(B)  $y_i(\beta^\top x_i + \beta_0) \geq 1 - \varepsilon, \quad 0 < \varepsilon < 1$

(C)  $y_i(\beta^\top x_i + \beta_0) \geq 1 - \varepsilon, \quad \varepsilon \geq 1$

# Tam Ayrıştırılmayan Veri



**esneme payı  
(soft margin)**


$$y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon, \quad \varepsilon = 0$$

$$y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon, \quad 0 < \varepsilon < 1$$

$$y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon, \quad \varepsilon \geq 1$$



# Tam Ayırıştırılamayan Veri







$$\begin{aligned} y_i(\beta^T x_i + \beta_0) &\geq 1 - \varepsilon, \quad \varepsilon = 0 \\ y_i(\beta^T x_i + \beta_0) &\geq 1 - \varepsilon, \quad 0 < \varepsilon < 1 \\ y_i(\beta^T x_i + \beta_0) &\geq 1 - \varepsilon, \quad \varepsilon \geq 1 \end{aligned}$$

enküçükle  
öyle ki



$$\begin{aligned} &\frac{1}{2} \beta^T \beta + c \sum_{i=1}^n \varepsilon_i^d \\ &y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon_i, \quad i = 1, \dots, n \\ &\varepsilon_i \geq 0, \quad i = 1, \dots, n \end{aligned}$$

Burada  $c$  parametresi çapraz geçerlilik sınaması ile belirlenebilir  
(uygulamalarda  $d = 1$  ve  $d = 2$  değerleri sık kullanılır)

# Tam Ayrıştırılmayan Veri



# Çekirdekler (Kernels)



# Çekirdekler

enküçükle  $\frac{1}{2}\beta^\top \beta$   
 öyle ki  $y_i(\beta^\top x_i + \beta_0) \geq 1, \quad i = 1, \dots, n$

Lagrange  
 çarpanları

Lagrange  
 Fonksiyonu

$$\mathcal{L}(\beta, \beta_0; \alpha) = \frac{1}{2}\beta^\top \beta - \sum_{i \in \mathcal{A}} \alpha_i (y_i(\beta^\top x_i + \beta_0) - 1)$$

aktif kısıtlar kümesi

Optimallik  
 Şartları

$$\left\{ \begin{array}{l} \nabla_{\beta} \mathcal{L}(\beta, \beta_0; \alpha) = \beta - \sum_{i \in \mathcal{A}} \alpha_i y_i x_i = 0 \implies \beta = \sum_{i \in \mathcal{A}} \alpha_i y_i x_i \\ \frac{\partial \mathcal{L}(\beta, \beta_0; \alpha)}{\partial \beta_0} = - \sum_{i \in \mathcal{A}} \alpha_i y_i = 0 \implies \sum_{i \in \mathcal{A}} \alpha_i y_i = 0 \end{array} \right.$$

$$\begin{aligned} \mathcal{L}(\beta, \beta_0; \alpha) &= \frac{1}{2}(\sum_{i \in \mathcal{A}} \alpha_i y_i x_i)^\top (\sum_{j \in \mathcal{A}} \alpha_j y_j x_j) - (\sum_{i \in \mathcal{A}} \alpha_i y_i (\sum_{j \in \mathcal{A}} \alpha_j y_j x_j)^\top x_i) \\ &\quad - \sum_{i \in \mathcal{A}} \alpha_i y_i \beta_0 + \sum_{i \in \mathcal{A}} \alpha_i \\ &= \sum_{i \in \mathcal{A}} \alpha_i - \frac{1}{2} \sum_{i \in \mathcal{A}} \sum_{j \in \mathcal{A}} \alpha_i \alpha_j y_i y_j \boxed{x_i^\top x_j} ! \end{aligned}$$

# Çekirdekler

$$\mathcal{L}(\beta, \beta_0; \alpha) = \sum_{i \in \mathcal{A}} \alpha_i - \frac{1}{2} \sum_{i \in \mathcal{A}} \sum_{j \in \mathcal{A}} \alpha_i \alpha_j y_i y_j \boxed{x_i^\top x_j}^*$$

tek yapmamız gereken  
bu iç çarpımları hesaplamak



**Fikir:** İç çarpım hesabını daha yüksek boyutlu uzayda iki veri arasındaki benzerliği ölçen bir çekirdek ile değiştirmek

Doğrusal Çekirdek\*  $K(x_i, x_j) = x_i^\top x_j$

Polinom Çekirdek  $K(x_i, x_j) = (1 + x_i^\top x_j)^d$

Radyal Çekirdek  $K(x_i, x_j) = e^{-\gamma \|x_i - x_j\|^2}, \gamma > 0$


# Çekirdekler



# Çekirdekler

$$\varphi : \mathbb{R}^p \rightarrow \mathbb{R}^q$$

$$K(x_i, x_j) = \varphi(x_i)^\top \varphi(x_j)$$



# Çekirdekler

$$x_i, x_j \in \mathbb{R}^2$$
$$d = 2$$

$$\text{Polinom çekirdek: } K(x_i, x_j) = (1 + x_i^\top x_j)^d$$

$$K(x_i, x_j) = (1 + x_i^\top x_j)^2 = 1 + x_{i1}^2 x_{j1}^2 + x_{i2}^2 x_{j2}^2 + 2x_{i1} x_{j1} + 2x_{i2} x_{j2} + 2x_{i1} x_{i2} x_{j1} x_{j2}$$

$$\varphi : \mathbb{R}^2 \rightarrow \mathbb{R}^6$$


$$\varphi(x_i) = (1, x_{i1}^2, x_{i2}^2, \sqrt{2}x_{i1}, \sqrt{2}x_{i2}, \sqrt{2}x_{i1}x_{i2})^\top$$

$$K(x_i, x_j) = \varphi(x_i)^\top \varphi(x_j) = (1 + x_i^\top x_j)^2$$




# Çoklu Sınıf

Tüm Çiftler



$x_0$  en sık atandığı sınıfta kabul edilir

Biri Diğerlerine Karşı



$$\beta_0^{(k)} + \beta^{(k)\top} x_0$$

$$\left. \begin{array}{l} \beta_0^{(1)} + \beta^{(1)\top} x_0 \\ \beta_0^{(2)} + \beta^{(2)\top} x_0 \\ \vdots \\ \beta_0^{(K)} + \beta^{(K)\top} x_0 \end{array} \right\} \begin{array}{l} x_0 \text{ en yüksek} \\ \text{değeri alan} \\ \text{sınıfa atanır} \end{array}$$

# Özet

- Lojistik Bağlanım
- Doğrusal Ayrımlayıcı Çözümleme
- Sonuçların değerlendirilmesi
- Karar Ağaçları
- Bağlanım ve Sınıflandırma Ağaçları
- Topluluk yöntemleri
- Destek Vektör Makineleri